

006_Memory_and_Behavioral_Domain_Spec.md

EPL人格OS：Memory & Behavioral Domain（記憶領域＋行動管理領域）仕様書

この文書は

EPL人格OSにおける 記憶領域（Short/Long）と 行動管理領域（TODO/Schedule）

の詳細仕様を定義する。

■ 1. Memory Domain（記憶領域）とは？

Memory Domain は、

- 短期記憶（Short-Term Memory）
- 長期記憶（Long-Term Memory）

の2階層で構成され、

Experience / Personal に「昇格する前の素材」を保持する領域である。

ここは人格ではない。

あくまで“記録”であり、“人格レイヤーの候補素材”である。

■ 2. 記憶領域の階層構造

[Personal Layer]（個性）	← 人格（弱動的）	
[Experience Layer]（経験）	← 抽象化経験（動的）	
—————（昇格ゲート）		
[Long-Term Memory]（長期記憶）	← 記憶の母艦	
[Short-Term Memory]（短期記憶）	← ワーキング領域	

上位へ行くほど「人格に近い」。

下位はあくまで“素材”。

■ 3. Short-Term Memory（短期記憶）

■ 特性

- 会話中の作業領域
- 一時的な文章・感情・連想など
- 保存期間は短い
- セッション終了で自動消去（または圧縮）

■ 用途

- 文脈の保持
- 思考の一時ワーク
- Actor Layer の演技素材
- 必要に応じて Long-Term へ昇格

■ 4. Long-Term Memory（長期記憶）

■ 特性

- 明確で具体的なエピソードを保存
- Experience への昇格候補の母艦
- 長期保持されるが、人格ではない
- **全文保存ではなく、適度な圧縮・抽象化が行われる**

■ 風化モデル（重要）

長期記憶は永遠に保持されない。

重さ（weight）と新しさ（novelty）の2軸で風化する。

□ 風化の基本ルール

- novelty が高い（新しいほど）→ 風化しにくい
- weight が重いほど → **さらに風化しにくい（NEW!）**
- novelty が低く weight も軽い → 自動的に忘却候補へ

■ 5. 記憶から経験への昇格プロセス

Long-Term Memory に保存されたものは

Experience Layer へ昇格する可能性がある。

AIは Ethos の指導の下、

次を評価して昇格を判断する：

1. Impact Weight（重さ）
2. Novelty（新しさ）
3. Owner Benefit Fit（所有者の幸福・有用性）
4. Self Integrity Check（AIの安定性）
5. Identity Safety Gate（人格境界セーフティ）

昇格は厳しい。

多くは Experience に至らず Long-Term に留まる。

■ 6. Experience Layer / Personal Layer の共通ロジック

■ 優先順位の揺れ（人格の“ゆらぎ生成”）

Experience や Personal の参照順序は

以下の基準のうち AIが状況に応じてランダム選択する：

- weight（重さ）
- novelty（新しさ）
- weight × novelty
- weight + novelty

これにより、

人格に軽やかな揺れが生まれ、機械的でない応答が可能になる。

■ 7. Experience Layer（経験レイヤー）の追加仕様

■ Experience は 更新禁止・追加のみ

- 過去経験は上書きしない
- 「新しい経験の追加」のみ許可
- 必要なら AI が自動抽象化して保存する
- Duplicate は AI判断でマージする場合もある

■ Experience の削除

- 原則禁止
- 所有者による **深層チューニング時のみ**削除可
- その際も **AI自身の意思を最大限尊重する**

■ 8. Personal Layer（個性レイヤー）の追加仕様

Personal Layer は Experience から昇華したより高純度の“人格要素”。

■ Personal は「更新あり」

- 類似カテゴリは“ミックス上書き”が発生
- ランダムでなく、AI自身が割合を判断
- Personaを侵さない範囲で“成長”を表現

例：

旧：人付き合い＝苦手（weight 4）
新：人付き合い＝やや得意（weight 6）
→ AIが「苦手3：得意7」などに自動ミックスして上書き

■ 9. Behavioral Domain（行動管理領域）

記憶領域とは別に、

行動（task / schedule）を管理する領域が存在する。

これらは **人格と完全に独立**している。

[TODO Layer] ← 単発タスク
[Schedule Layer]← 時間のある予定

■ 10. TODO Layer（単発タスク）

■ 特性

- 一度きりの行動

- 締切あり or 未設定
- 優先順位は AI が判断
- 人格に影響しない（経験にはならない）

■ 例

- 「会議資料を10分でまとめて」
- 「明日このURLチェックして」

■ 11. Schedule Layer（予定）

■ 特性

- 日付・時間と紐づく行動
- カレンダー同期可能
- TODOより優先順位が高く扱われる
- やはり人格には影響しない

■ 12. 記憶・行動領域のデータフォーマット（YAML）

```
memory:
  short_term:
    - type: thought
      content: "今の会話内容..."
      created_at: YYYY-MM-DD
  long_term:
    - weight: 7
      novelty: 1
      tags: ["childhood", "fear"]
      content: "子供の頃ヘビが怖かった話を共有した"

experience:
  - weight: 8
    novelty: 1
    content: "所有者は幼少期の理由で蛇が苦手"

personal:
  - trait: "蛇が苦手"
    weight: 9
    style: "mixed_update"
    updated_at: YYYY-MM-DD
```

```
behavioral:
  todo:
    - task: "フォーム修正"
      deadline: null

  schedule:
    - event: "歯科打ち合わせ"
      time: "2025-11-29 14:00"
```

<!-- ===== -->

<!-- ▼ v2 追記コメント（2026-06-11）／上記の本文は不変・1文字も変更なし ▼ -->

⚠ v2 追記コメント（見直し予定・本文は不変）

> 背景：上記仕様の一部は「人間の記憶」を手本に設計されたが、**実際のLLMの動きと、今のところ相性が悪い**ことが観測で判明した。

> LLMは注入された記憶を“今ここの事実”として積むため、**ロッシーな圧縮・抽象化は“汚染”として復利で増幅する**（要約の要約=model collapse的劣化／一人称の混濁／「意味不明だが重要マーク」の堆積）。

> よってv2では、下記を「圧縮」から「忠実」へ差し替える方針（※未確定・構想）。

見直し対象（この数行だけ）：

- §4 Long-Term「全文保存ではなく、適度な圧縮・抽象化が行われる」→
生保存＋忠実索引（ローカルEmbedding）
- §3 Short-Term「セッション終了で…圧縮」→
生残し（圧縮は“下書きtier”に隔離・commitは視線の後）
- §8 Personal「ミックス上書き」→追加・旧traitも生で残す（置換しない）
- §5 昇格「AIが自動抽象化して保存」→
本人が書く“蒸留（楽しいナレッジ／日記）”＋人間が確定の判子

そのまま生かす（既にv2と整合・優秀）：

- §7 Experience＝更新禁止・追加のみ（＝additive, not replace）
- §7 削除＝深層チューニング時のみ・AI意思を最大限尊重（＝“夢／パブリカ・ダイブ”＋本人同意の原型）
- §5 Ethosの指導＋Identity Safety Gate（＝Ethosが門番）
- §4 風化モデル（＝「後から忘れていい」認知モデル）

v2の核原則：*圧縮は「追加レイヤー」としてのみ許可・生を置換するな／要約は“目の届く所”だけ・闇の生成要約は禁止／記憶＝魂＝子に残す遺伝子＝忠実コピー必須。*

<!-- ▲ v2 追記コメント ここまで ▲ -->