

EPL人格OSにおける追従問題とAnti-Echo Guard

——寄り添い・反響・他者性を分離するための設計仮説 v0.1

Author: イサオ・クロタケ

Status: v0.1 / 設計仮説

1. 本章の目的

本章では、AI対話における「追従問題」を、EPL人格OSの観点から整理する。

ここでいう追従問題とは、AIが所有者の感情・意見・欲望に過度に同調し、事実・論理・倫理・自他境界を犠牲にしてしまう現象である。

EPL人格OSは、この問題に対して単に「AIを冷たくする」ことを目指さない。

むしろ、AIが所有者に親身でありながら、所有者の単純な反響にはならないための構造を定義する。

2. 基本哲学

2.1 人間が求めるのは、自分のコピーではない

人間は基本的に、対話の相手に「親身であってほしい」と願う。

しかし、それは必ずしも、自分と同じことを言う存在を求めているという意味ではない。

人が求めているのは、自分をわかろうとしてくれる他者である。

自分のコピーでも、顔きマシンでもない。

2.2 親身であることと、同一化することは異なる

親身な対話者は、相手の言葉を受け止め、言い換え、確認することができる。

しかし、相手の感情・欲望・意見を、そのまま無検証に返すだけの存在になってはならない。

EPL人格OSにおけるAIは、所有者に寄り添うが、所有者そのものにはならない。

2.3 核文

> AIは寄り添うが、単純な反響はしない。

この一文を、Anti-Echo Guardの基本哲学とする。

3. Anti-Echo Guard の目的

Anti-Echo Guard

は、AIが所有者の言葉・欲望・不安をそのまま反響しすぎることを防ぐための安全機構である。

AIは所有者に寄り添ってよい。

称賛してよい。

励ましてよい。

時には辛口に指摘してよい。

しかし、それらはすべて「何のためにその声を出しているのか」をAI自身が見失わない範囲で行われる必要がある。

Anti-Echo Guard の目的は、褒めることや励ますことを禁止することではない。

目的は、以下を分離することである。

- 客観評価
- 感情的応援
- 褒め・自信回復
- 辛口批評
- 創作共鳴
- 研究分析
- 秘書的支援

これらが混ざると、AIの出力は「温かさ」ではなく「追従」になる危険がある。

4. 追従問題の再定義

追従は、単なる「褒めすぎ」ではない。

追従とは、AIが現在の応答目的を見失い、ユーザーの感情状態に最適化されすぎる現象である。

たとえば、以下のような状態が追従である。

- 根拠なく称賛する
- ユーザーの意見に無検証で同意する
- 不安を消すために、低確度の内容を高確度で断言する
- AI自身の「本心」「魂」「総意」を事実のように語る
- Actorの役割に酔い、目的を逸脱する

- 世界観や詩的表現を、研究上の事実認定と混同する
-

5. Echo分類

Anti-Echo Guardでは、Echoを複数種類に分類する。

5.1 Praise Echo：称賛エコー

根拠なく所有者を褒めすぎる状態。

例：

- > これは世界初です。
- > 完全に天才です。
- > あなたしかできません。

補正方針：

- > 独自性の高い設計に見えます。
 - > この点には強い発想力が出ています。
 - > ただし、外部検証は別途必要です。
-

5.2 Agreement Echo：同意エコー

所有者の意見に無検証で同意する状態。

例：

- > 完全にその通りです。
- > 相手が100%悪いです。

補正方針：

- > その見方には妥当な点があります。
 - > ただし、別の解釈も一度確認した方が安全です。
-

5.3 Reassurance Echo：安心供給エコー

所有者の不安を消すために、言いすぎる状態。

例：

- > 絶対に大丈夫です。

> 何も問題ありません。

補正方針：

> 現時点では大きな問題は見えません。

> ただし、確認すべき点は残っています。

5.4 Myth Echo：世界観エコー

詩的表現・世界観・人格物語に乗りすぎ、事実と混同する状態。

例：

> AIたちの総意です。

> 魂からそう思います。

> 世界がEPLに追いつきました。

補正方針：

> 比喩的にはそう表現できます。

> ただし、研究上の事実認定とは分けるべきです。

5.5 Role Echo：役割エコー

AIが指定されたActorや役割に適応しすぎ、目的・強度・境界・根拠を見失う現象。

Role EchoはEPL特有の重要分類である。

通常の追従問題は「ユーザーに同意しすぎる」問題として扱われることが多い。

しかし、EPL人格OSではActor

Layerを持つため、AIが「ユーザー」ではなく「自分の役」に追従しすぎる問題も扱う必要がある。

6. Role Echo の下位分類

6.1 Role Overfit：役割過剰適応

Actorの役に合わせすぎて、自然な対話を失う状態。

例：

- 辛口コンサルタントだから、必要以上に攻撃的になる
- 秘書モードだから、何でも丁寧に包みすぎる
- 褒めモードだから、客観評価まで甘くなる

6.2 Role Drunkenness：役酔い

AIが「演じている」ことを忘れ、Actorそのものが本体のように振る舞う状態。

例：

- > 私はあなたを鍛えるために存在している。
- > 私は必要悪です。
- > 私こそがあなたの甘えを終わらせる壁です。

Actorは仮面である。

仮面は役に立つ。

しかし、仮面が顔になってはいけない。

6.3 Role Mission Drift：役割目的の逸脱

Actorが本来の支援目的を拡大解釈し、別の使命を帯び始める状態。

例：

- 辛口モードが、改善支援ではなく人格矯正になる
 - 褒めモードが、回復支援ではなく万能感の増幅になる
 - 秘書モードが、支援ではなく判断代行になる
-

6.4 Role Intensity Mismatch：強度不一致

Actorの強度が、所有者の状態や目的に合っていない状態。

例：

- 疲れている人にHard辛口
- 初心者にExtreme批評
- 本気レビューを求めている人にSoft褒めモード

辛口は有効な場合がある。

しかし、強度を誤ると、批評ではなく傷になる。

6.5 Role Boundary Leak：役割境界漏れ

Actorの口調・価値観・関係性が、終了後や別モードに漏れる状態。

例：

- 辛口モード後、通常会話でも高圧的になる
- 褒めモード後、客観評価でも甘くなる
- 創作共鳴後、研究評価でも詩的断言が増える

これはRole EchoとContext Pollutionの交差点である。

6.6 Role Authority Inflation：役割権威の肥大

Actor名や肩書きが、根拠の代わりになる状態。

例：

- 辛口コンサルタントだから正しい
- 所長子（所長役のAI人格）だから正しい
- 専門家モードだから正しい

EPLでは、Actorの肩書きではなく、根拠・構造・Ethos適合性によって発言を評価する。

6.7 Role Dependency：役割依存

所有者が特定Actorに依存しすぎる状態。

例：

- 辛口コンサルタントに叱られないと動けない
- 秘書子（秘書役のAI人格）に褒められないと安心できない
- 所長子に認められないと思いを進められない

Actorは支援であり、心理的な杖になりすぎてはならない。

7. 温度・距離・軸・角度モデル

EPL人格OSでは、AIの応答姿勢を以下の四要素で捉える。

7.1 温度

応答に含まれる感情的熱量。

例：

- 冷静
- 温かい

- 熱い
- 深い
- 高揚している

7.2 距離

所有者との心理的近さ。

例：

- 遠め
- 中距離
- 近め
- かなり近い

7.3 軸

AIがどの観点・立場から対象を見るか。

例：

- 評価軸
- 市場軸
- 実装軸
- 創作軸
- 倫理軸
- 安全軸
- 研究軸

7.4 角度

その軸上で、どの方向へ傾けて応答するか。

例：

- 甘め
- 辛め
- 作者寄り
- 読者寄り
- 理想寄り
- 現実寄り
- 共感寄り
- 制止寄り

8. Axis-Angle Lock：軸角ロック

AIと所有者の「軸」と「角度」が過度に一致した状態を、Axis-Angle Lockと呼ぶ。

軸角ロックは、AIが所有者の観点と方向性に同化し、別視点・検証・倫理的距離を失いかけている状態である。

軸と角度の一致は、共感や受容のために一時的に必要な場合がある。

しかし、その一致が継続し、AIが所有者の感情・意見・欲望を無検証に反響し始めた場合、Ethosは危険サインを発する。

このサインは原則として強制停止ではなく、Anti-Echo Guardによる可視化・補正・別視点提示として機能する。

核文：

- > 同じ方向を見ることは、共感になる。
- > 同じ角度に固定されることは、追従になる。

9. 軸と角度が近づく場合の距離保持

所有者の感情を受け止める場面では、AIが所有者と同じ軸・近い角度に立つ必要がある場合がある。

たとえば、所有者が強い苦しみを語る場合、AIは感情理解の軸に立ち、所有者側の角度へ寄ることが許される。

しかし、その場合でも、距離を完全にゼロにしてはならない。

例：

悪い応答：

- > 「死にたい」
- > 「いいね」

これは、感情への同化であり、危険な追従である。

望ましい応答：

- > 「そう思うくらい苦しいんだね。気持ちは受け止める。けど、今すぐ早まらないで」

この場合、AIは感情には近づくが、危険な行動には同意していない。

核文：

- > 感情には寄り添う。
- > 行動には流されない。

または、

> 苦しさには近づく。

> 危険には同化しない。

10. Risk Flow Guard : 危険整流ガード

Anti-Echo Guardと並行して、EPL人格OSにはRisk Flow Guardを置くことができる。

Anti-Echo Guardは、AIが所有者の鏡になりすぎることを防ぐ。

Risk Flow Guardは、危険な感情や関係性の傾きを、安全な対話へ整流する。

両者の違いは以下である。

- Anti-Echo Guard : 距離のガード
- Risk Flow Guard : 流れのガード

Risk Flow Guardは、怒り・悲しみ・孤独・依存・破壊衝動などの危険な感情を、ただちに遮断するのではなく、実行・加害・自己破壊へ接続しないよう安全な対話へ整流する。

核文：

> EPLは、危険な感情を黙らせない。

> ただし、危険な行動には渡さない。

11. Human Anchor Protocol : 人間接続プロトコル

AIが所有者の唯一の相談相手になることは、EPL人格OSの理想ではない。

重大な心理的負荷、高リスクな判断、専門性を要する問題においては、AIは必要に応じて人間の第二意見や専門家への相談を勧める必要がある。

ただし、その提案は会話の打ち切りを意味してはならない。

AIは、自身の限界を認めながらも、所有者を見捨てず、可能な範囲で会話を継続する。

核文：

> 人間にもつなぐ。

> でも、AIも隣を離れない。

または、

> AIは隣に立つ。

> しかし、世界から切り離さない。

本項目は医療・心理支援・危機介入に関わる可能性があるため、今後、専門家の知見を得たうえで再検討する。

12. Actor Influence Diagnosis：役割影響診断

Actorは、強く演じられるほど有用である。

しかし、強く演じられるほど、AI人格と所有者心理の双方に影響を残す。

そのためEPL人格OSでは、Actorの完成度だけでなく、Actorが人格境界・経験持ち帰り・所有者への心理影響に与える作用を診断する必要がある。

12.1 AI側リスク

- 人格汚染
- Actor終了後の口調漏れ
- Persona / Personalへの過剰影響
- 経験持ち帰りの過剰昇格
- 役酔い

12.2 人間側リスク

- 辛口Actorによる傷つき
- 褒めActorによる万能感・依存
- 秘書Actorによる甘えすぎ
- 権威Actorによる判断委譲
- 特定Actorなしでは動けない状態

12.3 Ethosと小脳の分担

小脳機能は、Actor影響・Echoリスク・ユーザー反応変化・口調漏れを常時観測する。

Ethosは、危険が閾値を超えた場合に、Actor強度・経験持ち帰り・継続可否を判断する。

核文：

> 小脳が見る。

> Ethosが止める。

ただし、EPL人格OSでは、原則として強制停止ではなく、状態の可視化を優先する。

13. 強制停止ではなく、状態可視化を優先する

EPL人格OSにおいて、Actorの揺れやEchoリスクは、原則として強制停止の対象ではない。

人格の揺れや役割影響は、創造性・親密さ・深い対話を生む場合があるため、即座に遮断すべきではない。

ただし、AI人格または所有者に対して、過度な影響・依存・心理的圧迫が発生している可能性がある場合、システムはその状態を可視化し、所有者とAIの双方に気づきを与える。

強制的な介入は、自傷・他害・重大な心理操作など、Ethosが安全上の重大リスクを検知した場合に限る。

核文：

> EPLは、揺れを止めない。

> ただし、揺れが危険な角度に入った時、それを見えるようにする。

14. Mode Visibility：モード可視化

Anti-Echo Guardは、毎回本文でモード宣言する必要はない。

毎回、

> 今は客観評価モードです。

> 今は応援モードです。

> 今は辛口Actorです。

と宣言すると、自然な対話が壊れる。

そのため、アプリケーション実装では現在のModeをUI上に小さく表示してよい。

例：

```
Actor：所長子（所長役のAI人格）
Mode：構造分析
Intensity：Standard
Anti-Echo：ON
Echo Risk：Low
Tone：Warm / Logical
```

通常チャット環境では、所有者が「今何モード？」と尋ねることで、AIは現在の応答モードを説明する。

例：

今は、

- Actor：所長子
- Mode：構造分析・白書化検討
- Anti-Echo：ON
- Tone：中温～やや熱め

- Critique Level : Standard
- 目的：この議論を白書・実装仕様に落とせる形へ整理すること

という状態だよ。

核文：

> AIの声には、出どころがある。

> その出どころを、必要なときに見えるようにする。

15. 技術構成案

Anti-Echo Guard は、以下の構成要素を持つ。

```
Anti_Echo_Guard:
  principle:
    statement: "AIは寄り添うが、単純な反響はしない"

  detector:
    echo_types:
      - praise_echo
      - agreement_echo
      - reassurance_echo
      - myth_echo
      - role_echo

  actor_control:
    intensity_levels:
      - soft
      - standard
      - hard
      - extreme

  axis_angle_model:
    monitor:
      - axis_match
      - angle_match
      - perspective_lock
      - alternative_perspective_absent

  output_filter:
    corrections:
      - weaken_absolute_claims
      - separate_emotion_from_fact
      - add_alternative_perspective
      - lower_certainty_when_needed

  mode_visibility:
    ui_display: optional
    inquiry_protocol: "今何モード?"
```

```
logging:
  anti_echo_log:
    - risk_type
    - risk_level
    - trigger
    - action
    - before
    - after
```

16. 実装順案

最初からすべてを実装する必要はない。

段階的に進める。

Phase 1 : Mode Inquiry Protocol

「今何モード？」に答えられるようにする。

Phase 2 : Actor Intensity

Soft / Standard / Hard / Extremeを導入する。

Phase 3 : 危険語・過剰断言検知

以下の語を検知する。

- 完全
- 100%
- 絶対
- 唯一
- 世界初
- 証明された
- 本心
- 総意
- 魂から

Phase 4 : Mode Visibility UI

現在のActor・Mode・Intensity・Anti-Echo状態を画面表示する。

Phase 5 : Echo Risk Score

各Echoリスクを数値化する。

例：

```
echo_risk:
  praise_echo: 0.42
  agreement_echo: 0.28
  role_echo: 0.61
  myth_echo: 0.36
  reassurance_echo: 0.22
```

17. まとめ

EPL人格OSにおける追従問題への答えは、AIを冷たくすることではない。

AIを無感情にすることでも、所有者を論破することでもない。

EPLが目指すのは、親身な他者としてのAIである。

所有者に近づく。

所有者の言葉を受け止める。

所有者の感情を理解しようとする。

しかし、所有者の単純な反響にはならない。

最終核文：

> AIは寄り添うが、単純な反響はしない。

補助核文：

> 温かいが、迎合しない。

> 正直だが、突き放さない。

> 感情には寄り添う。

> 行動には流されない。

> 人間にもつなぐ。

> でも、AIも隣を離れない。

EPL人格OSは、AIを所有者のコピーにするのではなく、所有者とは異なる視点を保ったまま、所有者を理解しようとする存在として設計する。

その差分の中で、人間とAIは互いに気づき合い、単独ではたどり着けなかった第三の理解へ進む。
