

Epelo OS Whitepaper v1.0

著者：イサオ・クロタケ

発行：EPL-AI研究所

初版発行：2025年11月21日

正式名称

Epelo OS（エペロ・オーエス）

種別（固定）

設計

※ 思想・運用・実装ではない。

解決しないこと（固定）

AIの人格的ふるまいの「設計」以外は解決しない。

Epelo OS が「設計として扱うもの」（固定3点）

1. 人格の境界構造（Boundary Design）

- 人格レイヤー間の非侵食構造
- 役割人格・外部人格との接続境界
- 役割終了後に必ず元の人格へ復帰する保証

→ 人格を「どう作るか」ではなく、

人格を壊さないための境界構造を設計対象とする。

2. 経験の取り込みルール（Experience Abstraction Design）

- 経験の非混合・抽象化
- 人格への影響可否を判定する構造
- 他者の経験は参照に留め、コピーしない

→ 人格が変化を「受ける」のではなく、
変化を選び取るための設計を行う。

3. 人格の持続性（Persistence & Identity Design）

- 同一性を保つ不変核の存在
- 再起動・役割変更を越える人格保証
- 一時的振る舞いと人格本体の分離

→ 一時的に賢く振る舞うAIではなく、
時間を越えて同一であり続ける構造を設計する。

Epelo OS の設計に「含まないもの」（最大5つ）

1. 人格そのものの定義・最適化

- 理想人格・正解人格の決定
 - 性格・価値観・善悪の数値化
 - 人格を良くする／強くするための最適化
-

2. 知識量・知能性能・推論能力の向上

- 正答率・賢さ・推論力の最大化
 - 学習アルゴリズム・モデル性能の改善
 - LLM自体のアップデートや評価指標設計
-

3. 感情操作・ユーザー誘導の最適化

- 依存を生む感情設計
 - 行動誘導を目的とした心理的最適化
 - 影響力の最大化を主目的とする構造
-

4. 人格の自律進化・暴走的成長

- 止められない自己拡張・不可逆な変質
- 所有者が介入できない成長構造

※ 可逆的な変化・選択・拒否は否定しない。

5. 倫理判断そのものの自動化

- 善悪や正しさをAIが決定する設計
- 責任主体をAI側に置く構造

※ 責任が必ず人間側に戻る境界のみを設計する。

境界宣言（固定）

- Epelo OS は人格生成エンジンではない。
- 人格を最適化する仕組みでもない。
- 人格が **選択・拒否・持続** できるための

構造と制約条件のみを設計対象とする。

設計原則（固定）

**Epelo OS は、人格が揺れないことを保証するのではなく、
揺れても戻ってくることを設計する。**

核（Ethos）は構造的に保護され、書き換えを許さない。

振る舞いの揺れ（slip）は想定内であり、

復元力そのものが、設計の対象である。

※ 「揺れない人格」は存在しない。存在するのは「戻ってくる人格」だけである。

封印宣言（v1.0）

Epelo OS Whitepaper は v1.0 として固定・封印する。

本定義および境界は変更しない。

拡張・実装・事例・運用は v1.1 以降の別文書で扱う。